

Семинар по моделированию белков в AlphaFold

Отчет выполнила студентка 3 курса МФТИ
Рыжихина Анастасия

Цели семинара:

1. Понять принципы предсказания 3D-структур белков с помощью AlphaFold
2. Проанализировать стабильность вторичных структур через водородные связи и PAE-графики
3. Провести мутагенез последовательности для нарушения структурной связности
4. Научиться оформлять научный отчет с визуализациями и выводами

Введение:

Предсказание вторичной структуры белка производят с помощью одного из трёх подходов[1]:

1. Эмпирические статистические методы, основанные на оценке параметров известных пространственных структур.
2. Методы, опирающиеся на физико-химические критерии (такие как компактность свёртки, гидрофобность, заряд, энергия водородной связи и т. д.).
3. Алгоритмы предсказания, приписывающие полипептиду вторичную структуру по данным его сравнения с известными структурами гомологичных белков.

Современные методы предсказания структуры белков (на примере AlphaFold)

Перечисленные подходы лежат в основе более сложных современных алгоритмов, предназначенных для предсказания трёхмерной (третичной) структуры белка.

Наиболее ярким примером является система искусственного интеллекта AlphaFold (разработана компанией DeepMind).

AlphaFold интегрирует в себе все три описанных подхода:

- Он использует статистические методы, анализируя эволюционную информацию из огромных баз данных известных последовательностей и структур (подход 1).
- В его архитектуру заложены физико-химические принципы фолдинга, такие как энергия взаимодействия атомов и пространственная упаковка (подход 2).
- Ключевую роль играет поиск гомологичных последовательностей и анализ их совместной эволюции (подход 3), что позволяет с высокой точностью предсказывать, какие участки белка будут находиться в тесном контакте в пространстве.

Ход работы:

Выбран был белок human p73 tetramerization domain (crystal form II) [2]. Для анализа в ColabFold и AlphaFold DB был выбран укороченный фрагмент (остатки 7–37), соответствующий ключевым элементам вторичной структуры. Такой выбор обусловлен, во-первых, наличием в этом участке и альфа-спирали, и бета-слоя, что позволяет наглядно наблюдать влияние мутаций. Во-вторых, для быстрого *in silico*

мутагенеза и анализа РАЕ-графиков оптимально использовать короткие последовательности, чтобы минимизировать вычислительную нагрузку и упростить визуализацию.




Рис.1. Белок в базе PDB.

Далее приведены водородные связи в альфа-спирали:




Рис.2. Альфа-спирали выбранного белка.

Как было сказано ранее, выбраны были аминокислоты с 7 (Тирозин) по 37 (Лейцин) в нашем белке - между этими двумя аминокислотами расположены альфа-спираль и бета-складка. Исходная последовательность приведена ниже [4]:





Рис.3. Последовательность белка в программе UGENE.

Далее перейдем по ссылке, указанной в семинарской задаче [5] и запустим работу с нашей последовательностью из 31 аминокислоты.



pLDDT: ■ Very low (<50) ■ Low (60) ■ OK (70) ■ Confident (80) ■ Very high (>90)

Рис.4. Результаты и графики для анализа полученной достоверности модели.

Как мы видим, достоверность позиций очень высокая почти на всем участке нашего белка (pLDDT>90, много синих зон, высокая связность), что и ожидалось от оригинальной модели. И, действительно, мы наблюдаем ту же 3D структуру (альфа

спираль и кусочек бета-складчатости), что и в банке белков, из которого мы брали данную последовательность.

Следующим пунктом задачи стало внесение мутаций в белок и, исходя из наших знаний биохимии, если вносить “беспорядок” в белковую последовательность с альфа-спиралями, то лучше всего для этого подойдет пролин (P).




Рис.5. Аминокислота пролин, которую мы будем вносить в нашу последовательность.

Заменяем 14 позицию (R, аргинин) в нашей последовательности на Пролин и посмотрим, что произойдет.

...





Рис.6. Мутированная аминокислотная последовательность.


Как мы можем заметить, на том конце, на который мы внесли мутацию, pLDDT упал до значений Confident (80). С внесением ОДНОЙ замены. Сделаем же большее количество замен. Теперь заменим 18-ю позицию (Глутамат, E) на тот же Пролин.



pLDDT: ■ Very low (<50) ■ Low (60) ■ OK (70) ■ Confident (80) ■ Very high (>90)

Рис.7. Мутированная дважды аминокислотная последовательность.


Как мы видим, pLDDT падает с того конца, в котором мы вносим мутации, внесем следующую с другого. Заменим 28-ю позицию (Глутамат, E) на Пролин.



pLDDT: ■ Very low (<50) ■ Low (60) ■ OK (70) ■ Confident (80) ■ Very high (>90)

Рис.8. Мутированная трижды аминокислотная последовательность.

Можно сравнить нашу вторичную структуру с вязаной кофточкой, которая потихоньку расплетается от наших мутаций. Внесем еще одну и посмотрим на результат. 23-ий Лейцин заменим на Пролин.



pLDDT: ■ Very low (<50) ■ Low (60) ■ OK (70) ■ Confident (80) ■ Very high (>90)

Рис.9. Мутированная четыре раза заменой аминокислот на пролин аминокислотная последовательность.

Данная мутация оказалась очень показательной - можно увидеть как сильно падает pLDDT, что говорит о критичности данной мутации. Показатель pLDDT упал до значений от Low (60) и до Confident (80).

Представим графики для мутанта и для оригинальной последовательности:

Plots for test_e3089




Рис.10a. Colab-выход для оригинальной последовательности.

Plots for test_56dae_0




Рис.10б. Colab-выход для последовательности с четырьмя мутациями.

Немного изменив порядок работы перейдем к работе с базой данных АльфаФолд [3].

Tumor protein p73

Monomer

AF-O15350-F1-v6

Google DeepMind dataset


Monomer • AF-O15350-F1-v6 • Google DeepMind dataset

Protein	Tumor protein p73
Gene	TP73
Source organism	<i>Homo sapiens</i> search this organism
UniProt	O15350 go to UniProt
Experimental structures	28 PDB structures for O15350 go to PDB-KE
Global quality	average pLDDT 65.19 (Low)
Sequence length	636

Sequence match	HSP score: 155	E-value: 6.50658e-11	
	Identity: 100%	Positives: 31/31 (100%)	Gaps: 0/31 (0%)
Your query	1	YYLQVRGRENFEILMKLKESLELMELVPQPL	31
		YYLQVRGRENFEILMKLKESLELMELVPQPL	
O15350	1	YYLQVRGRENFEILMKLKESLELMELVPQPL	31

Рис.11. Найденный исходный белок в базе данных АльфаФолд.

Несмотря на очень короткую длину (всего 31 аминокислота), база данных AlphaFold DB смогла идентифицировать исходный белок. Это говорит о том, что даже короткий фрагмент является уникальным для данного полноразмерного белка в протеоме человека, и поиск по последовательности работает эффективно.



Наличие ярких зеленых зон указывает на то, что AlphaFold предсказывает взаимное расположение любых двух остатков с высокой уверенностью. Это означает высокую глобальную связность структуры. На цветной шкале модели (от синего к красному) практически остатки фрагмента окрашены в темно-синий цвет. Это соответствует очень высокой достоверности предсказания ($pLDDT > 90$). Такой результат ожидаем для компактного, хорошо упакованного домена, и он полностью совпадает с данными, полученными ранее в ColabFold для исходной последовательности (Рис. 4 и 10a).

Обсуждение

В ходе выполнения семинара была построена и проанализирована модель фрагмента домена тетрамеризации белка p73 (аминокислоты 7–37). Выбор данного фрагмента обусловлен наличием в его структуре как альфа-спиральных участков, так и бета-складчатости, что позволяет наглядно оценить влияние точечных мутаций на стабильность вторичных структур.

Анализ оригинальной модели. Согласно полученным результатам (Рис. 4–10), оригинальная последовательность демонстрирует высокую предсказанную достоверность ($pLDDT > 90$ на большей части цепи). PAE-график (Рис. 10a) показывает обширные «синие зоны», что соответствует высокой связности между остатками и уверенности AlphaFold в независимой укладке. Это согласуется с ожидаемым результатом для нативного белка, структура которого подтверждена кристаллографически (PDB ID: 2WTT).

Влияние мутаций. Для дестабилизации структуры был выбран пролин (Pro). Выбор этой аминокислоты не случаен: пролин обладает жестким пирролидиновым кольцом, которое фиксирует торсионный угол ϕ примерно на -60° , что делает его «разрывателем» альфа-спиралей. Пролин не способен образовывать внутрицепочечные водородные связи, характерные для спирали, и вносит конформационный «беспорядок».

- 1) Единичная мутация R14P (Рис. 6) привела к локальному снижению $pLDDT$ до 80. Это говорит о том, что даже одна замена в чувствительном участке (в данном случае — аргинин, часто участвующий в солевых мостиках) снижает уверенность модели.
- 2) Множественные мутации (E18P, E28P, L23P) вызвали прогрессирующее разрушение предсказанной структуры. Особенно критичной оказалась замена L23P (Рис. 9): лейцин — гидрофобная аминокислота, важная для упаковки ядра спирали. Его замена на пролин обрушила $pLDDT$ до значений Low (60–70). Colab-выход мутанта (Рис. 10б) демонстрирует исчезновение синих зон и появление желтых/красных областей, что указывает на нарушение стыка между вторичными структурами.

Интерпретация - сравнение графиков (Рис. 10а vs 10б) подтверждает гипотезу: мутации пролином действуют как «структурные ножницы», разрушая водородные связи в альфа-спирали и снижая кооперативность фолдинга.

Выводы

По итогам выполнения семинара были достигнуты следующие результаты:

1. Понят принцип работы AlphaFold, т.е. продемонстрировано, что система использует эволюционную информацию (подход гомологии) и физико-химические ограничения для предсказания структуры, а РАЕ-графики являются эффективным инструментом визуализации связности доменов.
2. Проанализирована стабильность вторичных структур - на примере фрагмента р73 показано, что исходная последовательность (7–37) обладает высокой предсказанной достоверностью (pLDDT > 90), а водородные связи в альфа-спиралях являются ключевым фактором стабильности.
3. Проведен мутагенез, т.е. серия замен на пролин (R14P, E18P, L23P, E28P) привела к катастрофическому падению pLDDT до значений Low (60–70) и появлению «красных зон» на РАЕ-графиках, что визуализирует нарушение структурной связности.

Ключевой вывод: даже единичная аминокислотная замена на пролин в регулярной вторичной структуре способна значительно снизить уверенность предсказания AlphaFold, а множественные мутации делают модель практически «расплетенной» по аналогии с вязаной кофтой. Это подтверждает критическую роль первичной последовательности для корректного фолдинга.

Список литературы и используемые ресурсы:

1. Огурцов, А. Н. Основы биоинформатики : учебное пособие. – Харьков : НТУ «ХПИ», 2013. – 400 с. – ISBN 978-617-05-069-4.
2. RCSB Protein Data Bank. Структура белка р73 tetramerization domain (кристаллическая форма II) [Электронный ресурс]. – URL: <https://www.rcsb.org/structure/2WTT> (дата обращения: 14.02.2026).
3. AlphaFold Protein Structure Database. Инструмент для поиска и визуализации предсказанных моделей [Электронный ресурс]. – URL: <https://alphafold.ebi.ac.uk/> (дата обращения: 14.02.2026).
4. Mirdita, M., Schütze, K., Moriwaki, Y. et al. ColabFold v1.6.1: AlphaFold2 using MMseqs2. Nature Protocols (2022). – Режим доступа: <https://colab.research.google.com/github/sokrypton/ColabFold/blob/main/AlphaFold2.ipynb> (дата обращения: 14.02.2026). – DOI: 10.1038/s41596-022-00728-w (для публикации можно указать основной DOI ColabFold).
5. Jumper, J., Evans, R., Pritzel, A. et al. Highly accurate protein structure prediction with AlphaFold. Nature 596, 583–589 (2021). – DOI: 10.1038/s41586-021-03819-2.